CitizenBike — Análise Estatística e Previsão da Demanda por Bicicletas Compartilhadas

Global Solution 2026 — 2º Semestre

Curso: Ciência da Computação

Disciplina: Modelagem Linear para Aprendizado de Máquina

Professor: Rodolfo Magliari de Paiva

Turma: 1CCPI

Integrantes

- Rafael Gandolfi Gonçalves — RM 569036
- Guilherme Miranda — RM 573107
- Carlos Eduardo — RM 572949

1.Introdução

A mobilidade urbana representa um dos principais desafios das cidades modernas, especialmente diante da necessidade de desenvolver alternativas de transporte mais sustentáveis, acessíveis e eficientes. Nesse contexto, os sistemas de bicicletas compartilhadas contribuem para a diversificação dos meios de transporte e para a melhoria da qualidade de vida da população.

O projeto CitizenBike foi desenvolvido no contexto do desafio CitizenTech, com o objetivo de analisar e prever a demanda por bicicletas compartilhadas por meio de técnicas estatísticas e modelos de regressão implementados na linguagem Python.

Para o desenvolvimento do estudo, foi utilizada a base de dados real *Bike Sharing Dataset*, disponibilizada pelo UCI Machine Learning Repository. O conjunto de dados contém 731 registros diários referentes aos anos de 2011 e 2012, incluindo informações sobre a quantidade de bicicletas alugadas, temperatura, umidade e velocidade do vento.

A análise contempla o cálculo de probabilidades utilizando a Distribuição Normal, testes de hipótese para médias, análise bivariada, regressão linear simples, regressão linear múltipla e regressão logística binária. Essas técnicas permitem identificar associações entre condições climáticas e demanda, desenvolver modelos preditivos e avaliar estatisticamente os resultados obtidos.

Espera-se que as informações extraídas contribuam para compreender os padrões históricos de utilização das bicicletas compartilhadas e demonstrar como a análise de dados pode auxiliar o planejamento da mobilidade urbana.

1.1 Objetivo Geral

Analisar a relação entre as condições climáticas e a demanda por bicicletas compartilhadas, utilizando métodos estatísticos e modelos de regressão em Python para identificar padrões, realizar previsões e apoiar decisões relacionadas à mobilidade urbana.

1.2 Objetivos Específicos

- Calcular probabilidades relacionadas à quantidade diária de bicicletas alugadas.
- Realizar testes de hipótese para comparar médias amostrais com a média populacional de referência.
- Investigar a correlação entre temperatura e quantidade de aluguéis.
- Desenvolver modelos de regressão linear simples e múltipla para prever a demanda.
- Aplicar regressão logística binária para classificar a demanda em alta ou baixa.
- Interpretar os resultados estatísticos e identificar informações relevantes para o planejamento da mobilidade urbana.

2. Descrição da Base de Dados

Para o desenvolvimento do projeto CitizenBike, foi utilizada a base de dados *Bike Sharing Dataset*, disponibilizada pelo UCI Machine Learning Repository. O conjunto reúne informações reais sobre o aluguel de bicicletas compartilhadas nos anos de 2011 e 2012, permitindo analisar a influência das condições climáticas na demanda pelo serviço.

Foi utilizado o arquivo day.csv, composto por 731 registros diários e 16 variáveis. Cada registro representa um dia de funcionamento do sistema de bicicletas compartilhadas.

A base foi carregada e analisada utilizando a biblioteca Pandas, na linguagem Python. A verificação inicial confirmou que todas as 16 colunas possuem 731 valores não nulos, não sendo necessário realizar tratamento de valores ausentes.

```
========== INFORMAÇÕES ==========
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     731 non-null    int64
 1   dteday      731 non-null    object
 2   season      731 non-null    int64
 3   yr          731 non-null    int64
 4   mnth        731 non-null    int64
 5   holiday     731 non-null    int64
 6   weekday     731 non-null    int64
 7   workingday  731 non-null    int64
 8   weathersit  731 non-null    int64
 9   temp        731 non-null    float64
 10  atemp       731 non-null    float64
 11  hum         731 non-null    float64
 12  windspeed   731 non-null    float64
 13  casual      731 non-null    int64
 14  registered  731 non-null    int64
 15  cnt         731 non-null    int64
dtypes: float64(4), int64(11), object(1)
memory usage: 91.5+ KB
```

2.1 Variáveis utilizadas

Para as análises estatísticas e os modelos de regressão, foram selecionadas as seguintes variáveis:

Variável	Descrição
cnt	Quantidade total de bicicletas alugadas diariamente
temp	Temperatura normalizada
hum	Umidade relativa normalizada
windspeed	Velocidade do vento normalizada

A variável cnt foi utilizada como variável dependente nos modelos de regressão linear, enquanto as variáveis climáticas foram utilizadas para explicar e prever a demanda.

Para a regressão logística binária, foi criada a variável demanda_alta, que classifica os registros em demanda baixa (0) ou alta (1), utilizando como referência a mediana da quantidade diária de aluguéis.

2.1 Estatísticas Descritivas

```
========= ESTATÍSTICAS =========
            instant      season          yr        mnth     holiday     weekday  workingday  weathersit        temp       atemp         hum   windspeed      casual  registered         cnt
count    731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000  731.000000
mean     366.000000    2.496580    0.500684    6.519836    0.028728    2.997264    0.683995    1.395349    0.495385    0.474354    0.627894    0.190486  848.176471 3656.172367 4504.348837
std      211.165812    1.110807    0.500342    3.451913    0.167155    2.004787    0.465233    0.544894    0.183051    0.162961    0.142429    0.077498  686.622488 1560.256377 1937.211452
min        1.000000    1.000000    0.000000    1.000000    0.000000    0.000000    0.000000    1.000000    0.059130    0.079070    0.000000    0.022392    2.000000   20.000000   22.000000
25%      183.500000    2.000000    0.000000    4.000000    0.000000    1.000000    0.000000    1.000000    0.337083    0.337842    0.520000    0.134950  315.500000 2497.000000 3152.000000
50%      366.000000    3.000000    1.000000    7.000000    0.000000    3.000000    1.000000    1.000000    0.498333    0.486733    0.626667    0.180975  713.000000 3662.000000 4548.000000
75%      548.500000    3.000000    1.000000   10.000000    0.000000    5.000000    1.000000    2.000000    0.655417    0.608602    0.730209    0.233214 1096.000000 4776.500000 5956.000000
max      731.000000    4.000000    1.000000   12.000000    1.000000    6.000000    1.000000    3.000000    0.861667    0.840896    0.972500    0.507463 3410.000000 6946.000000 8714.000000
```

A análise descritiva permitiu identificar as principais características dos dados.

Medida	Temperatura	Umidade	Vento	Aluguéis
Média	0,4954	0,6279	0,1905	4.504,35
Desvio padrão amostral	0,1831	0,1424	0,0775	1.937,21
Mínimo	0,0591	0,0000	0,0224	22
Mediana	0,4983	0,6267	0,1810	4.548
Máximo	0,8617	0,9725	0,5075	8.714

A quantidade média de bicicletas alugadas foi de aproximadamente 4.504 por dia, enquanto a mediana foi de 4.548. O menor número registrado foi de 22 aluguéis e o maior foi de 8.714.

O desvio padrão de aproximadamente 1.937 aluguéis indica uma variação considerável na demanda diária. Esses resultados demonstram a importância de investigar os fatores associados às oscilações na utilização do serviço.

3. Análise de Probabilidade – Distribuição Normal

```
========== EXERCÍCIO 02 ==========
Média: 4504.35
Mediana: 4548.00
Desvio padrão: 1935.89

a) Probabilidade: 0.5000 (50.00%)
b) Probabilidade: 0.4910 (49.10%)
```

Para a análise de probabilidade, foi selecionada a variável cnt, que representa a quantidade total de bicicletas alugadas diariamente. Conforme solicitado no enunciado, foi assumido que essa variável segue uma Distribuição Normal de Probabilidade.

A partir dos 731 registros da base de dados, foram obtidas as seguintes medidas estatísticas:

Medida	Resultado
Média populacional	4.504,35
Mediana	4.548,00
Desvio padrão populacional	1.935,89

3.1 Probabilidade de a variável ser menor que a média

O primeiro cálculo teve como objetivo determinar a probabilidade de a quantidade diária de bicicletas alugadas ser inferior à média dos registros.

Foi utilizada a função `norm.cdf()` da biblioteca SciPy, obtendo-se:

$$
P(X<4504,35)=0,5000=50,00\%
$$

O resultado indica que, sob a hipótese de Distribuição Normal, existe uma probabilidade de 50% de a quantidade diária de aluguéis ser inferior à média. Isso ocorre porque a Distribuição Normal é simétrica em relação à média.

O evento pode ser classificado como equiprovável, pois apresenta a mesma probabilidade de ocorrer ou não ocorrer.

3.2 Probabilidade de a variável ser maior que a mediana

O segundo cálculo teve como objetivo determinar a probabilidade de a quantidade diária de bicicletas alugadas superar a mediana dos registros.

Foi utilizada a função `norm.sf()` da biblioteca SciPy, obtendo-se:

$$
P(X>4548)=0,4910=49,10\%
$$

O resultado indica que, considerando a Distribuição Normal ajustada pela média e pelo desvio padrão dos registros, existe uma probabilidade aproximada de 49,10% de a quantidade diária de aluguéis superar 4.548 bicicletas.

O evento apresenta probabilidade próxima de 50%, sendo classificado como aproximadamente equiprovável.

3.3 Interpretação dos Resultados

As probabilidades obtidas demonstram que os valores da média e da mediana estão próximos, resultando em probabilidades semelhantes.

Esses resultados permitem compreender a distribuição teórica da demanda diária por bicicletas compartilhadas, servindo como base para as análises estatísticas posteriores.

4. Testes de Hipótese para Média

```
========== EXERCÍCIO 03 ==========

========== ITEM A ==========
Média populacional: 4504.3488372093025
Média amostral: 4364.15
Z calculado: -0.32387665128324244
Z crítico: -1.5547735945968535
Decisão: Não rejeita H0

========== ITEM B ==========
Média populacional: 4504.3488372093025
Média amostral: 4769.56
Z calculado: 0.6849865353713863
Z crítico: 1.3407550336902165
Decisão: Não rejeita H0
```

Para a realização dos testes de hipótese, foi utilizada a variável cnt, que representa a quantidade diária de bicicletas alugadas. O objetivo foi verificar se as médias de duas amostras apresentam evidências estatísticas de serem inferiores ou superiores à média populacional de referência.

A população considerada corresponde aos 731 registros do arquivo day.csv, apresentando média de 4.504,35 bicicletas e desvio padrão populacional de 1.935,89.

4.1 Metodologia de Amostragem

Foram selecionadas duas amostras aleatórias simples, sem reposição, utilizando o método sample() da biblioteca Pandas.

No item A, foram selecionados 20 registros, utilizando random_state=42. No item B, foram selecionados 25 registros, utilizando random_state=43.

A utilização de sementes aleatórias fixas permite reproduzir os resultados obtidos. Para os dois testes, foi utilizado o teste Z para a média, considerando o desvio padrão populacional dos registros e a hipótese de Distribuição Normal solicitada no enunciado.

4.2 Teste de Hipótese – Item A

O primeiro teste teve como objetivo verificar se a média populacional é inferior à média de referência de 4.504,35 bicicletas, considerando uma amostra de 20 registros e nível de significância de 6%.

As hipóteses estabelecidas foram:

[
H_0:\mu=4504,35
]

[
H_1:\mu<4504,35
]

Os resultados obtidos foram:

Medida	Resultado
Média populacional de referência	4.504,35
Média amostral	4.364,15
Tamanho da amostra	20
Nível de significância	6%
Z calculado	-0,3239
Z crítico	-1,5548

Como o Z calculado (-0,3239) é maior que o Z crítico (-1,5548), não se rejeita a hipótese nula.

Portanto, ao nível de significância de 6%, não existem evidências estatísticas suficientes para concluir que a média populacional seja inferior à média de referência.

4.3 Teste de Hipótese – Item B

O segundo teste teve como objetivo verificar se a média populacional é superior à média de referência de 4.504,35 bicicletas, considerando uma amostra de 25 registros e nível de significância de 9%.

As hipóteses estabelecidas foram:

[
H_0:\mu=4504,35
]

[
H_1:\mu>4504,35
]

Os resultados obtidos foram:

Medida	Resultado
Média populacional de referência	4.504,35
Média amostral	4.769,56
Tamanho da amostra	25
Nível de significância	9%
Z calculado	0,6850
Z crítico	1,3408

Como o Z calculado (0,6850) é menor que o Z crítico (1,3408), não se rejeita a hipótese nula.

Portanto, ao nível de significância de 9%, não existem evidências estatísticas suficientes para concluir que a média populacional seja superior à média de referência.

4.4 Interpretação dos Resultados

Os dois testes de hipótese não apresentaram evidências estatísticas suficientes para rejeitar a hipótese nula nos respectivos níveis de significância.

Embora as médias amostrais sejam diferentes da média populacional de referência, essas diferenças não foram estatisticamente significativas segundo os testes realizados.

Os resultados demonstram a aplicação da inferência estatística na análise da demanda por bicicletas compartilhadas, permitindo avaliar diferenças entre médias amostrais e valores de referência.

Como as amostras foram retiradas da própria base utilizada para calcular a média populacional de referência, as conclusões se limitam ao exercício estatístico realizado sobre esses registros históricos.

5. Análise Bivariada e Regressão Linear Simples

A análise bivariada teve como objetivo investigar a relação entre a temperatura e a quantidade diária de bicicletas alugadas, utilizando os 731 registros do dataset.

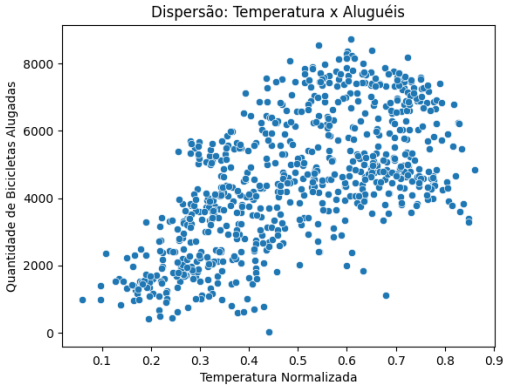
Foram selecionadas duas variáveis quantitativas:

- Variável independente (X): temp — temperatura normalizada.

- Variável dependente (Y): cnt — quantidade diária de bicicletas alugadas.

5.1 Gráfico de Dispersão

O gráfico de dispersão foi utilizado para visualizar a associação entre temperatura e quantidade de aluguéis.



Observa-se uma tendência crescente na distribuição dos pontos, indicando que temperaturas mais elevadas estão associadas a uma maior quantidade de bicicletas alugadas.

Entretanto, a dispersão dos registros demonstra que a temperatura, isoladamente, não explica toda a variação da demanda.

5.2 Covariância e Correlação de Pearson

Para quantificar a associação entre as variáveis, foram calculadas a covariância e a correlação linear de Pearson.

```
========== EXERCÍCIO 04 ==========

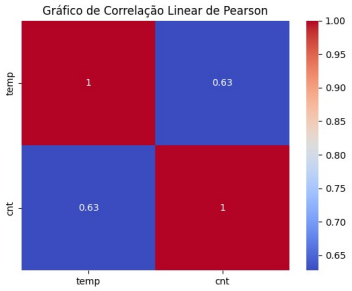
Covariância: 222.5147004530551
Correlação de Pearson: 0.6274940090334918
```

A covariância positiva indica que a temperatura e a quantidade de aluguéis tendem a variar no mesmo sentido.

O coeficiente de Pearson de 0,6275 demonstra uma correlação linear positiva moderada, indicando que maiores temperaturas estão associadas, em geral, a maiores quantidades de bicicletas alugadas.

5.3 Gráfico de Correlação Linear De Pearson

A relação entre as variáveis também foi representada por meio de um mapa de calor, permitindo visualizar o coeficiente de correlação.



O gráfico confirma a correlação positiva de aproximadamente 0,63 entre as variáveis, reforçando a existência de uma associação linear entre temperatura e demanda.

5.4 Regressão Linear Simples

Foi desenvolvido um modelo de Regressão Linear Simples utilizando a biblioteca Statsmodels, com o objetivo de estimar a quantidade de bicicletas alugadas a partir da temperatura.

A equação obtida foi:

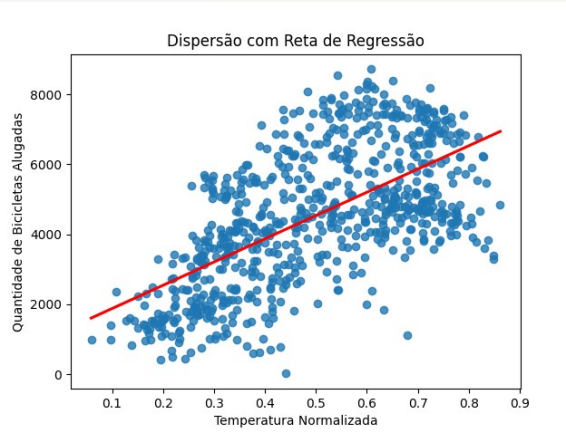
```
Equação da Regressão Linear Simples:
Y = 1214.6421 + (6640.7100 * X)
```

Onde:

- (Y): quantidade estimada de bicicletas alugadas.
- (X): temperatura normalizada.
- (1214,6421): intercepto da regressão.
- (6640,7100): coeficiente angular da temperatura.

O coeficiente angular positivo indica que o aumento da temperatura normalizada está associado ao aumento esperado na quantidade de bicicletas alugadas.

A reta ajustada foi representada no gráfico de dispersão.



5.5 Adequação do Modelo

Para verificar a adequação estatística do modelo, foram analisados o coeficiente de determinação (R^2) e o Teste F.

```
========== ADEQUAÇÃO DO MODELO ==========
                            OLS Regression Results
==============================================================================
Dep. Variable:                    cnt   R-squared:                       0.394
Model:                            OLS   Adj. R-squared:                  0.393
Method:                 Least Squares   F-statistic:                     473.5
Date:                Wed, 04 Nov 2026   Prob (F-statistic):           2.81e-81
Time:                        21:53:42   Log-Likelihood:                -6386.8
No. Observations:                 731   AIC:                         1.278e+04
Df Residuals:                     729   BIC:                         1.279e+04
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       1214.6421    161.164      7.537      0.000     898.242    1531.042
temp        6640.7100    305.188     21.759      0.000    6041.558    7239.862
==============================================================================
Omnibus:                       20.477   Durbin-Watson:                   0.468
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               12.566
Skew:                           0.167   Prob(JB):                      0.00187
Kurtosis:                       2.452   Cond. No.                         6.85
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
R²: 0.3937487313729242
Teste F: 473.4717105349776
P-valor do Teste F: 2.810622397589647e-81
```

O R^2 de 39,37% indica que aproximadamente 39,37% da variabilidade observada na quantidade diária de bicicletas alugadas é explicada pela temperatura no modelo de regressão linear simples.

O Teste F apresentou p-valor inferior a 0,05, indicando que a regressão é estatisticamente significativa ao nível de 5%.

Apesar da significância estatística, parte considerável da variação da demanda permanece sem explicação, sugerindo a influência de outros fatores.

5.6 Previsão

Foi realizada uma previsão considerando uma temperatura normalizada de 0,5.

```
========== PREVISÃO ==========
Temperatura normalizada: 0.5
Quantidade prevista: 4535 bicicletas
```

Assim, para uma temperatura normalizada de 0,5, o modelo prevê aproximadamente 4.535 bicicletas alugadas por dia.

5.7 Interpretação dos resultados

Os resultados demonstram uma associação positiva entre temperatura e demanda por bicicletas compartilhadas.

A análise indica que a temperatura é uma variável relevante para compreender as oscilações na utilização do serviço. Entretanto, o R^2 obtido mostra que outros fatores também devem ser considerados.

Essas informações podem auxiliar no planejamento da disponibilidade de bicicletas em períodos com condições climáticas favoráveis. Contudo, os resultados representam associações estatísticas nos dados históricos e não demonstram, isoladamente, uma relação causal.

6. Análise Multivariada e Regressão Linear Múltipla

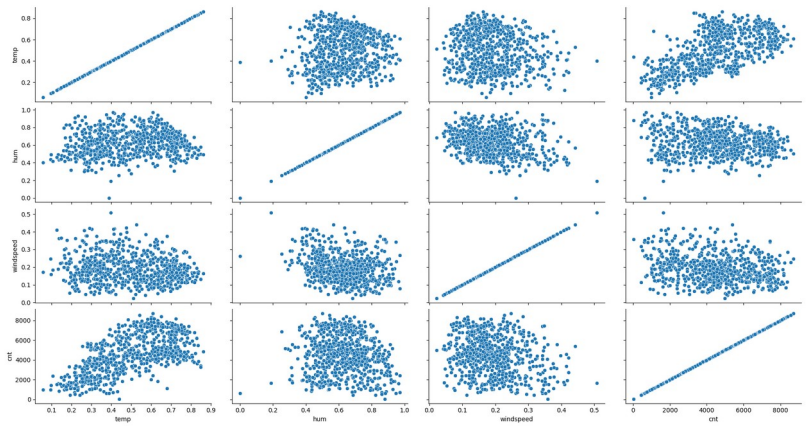
A análise multivariada teve como objetivo investigar a relação entre diferentes condições climáticas e a quantidade diária de bicicletas alugadas. Foram utilizados os 731 registros da base de dados, considerando três variáveis explicativas e uma variável dependente.

As variáveis selecionadas foram:

- X_1 — temp: temperatura normalizada.
- X_2 — hum: umidade relativa normalizada.
- X_3 — windspeed: velocidade do vento normalizada.
- Y — cnt: quantidade diária de bicicletas alugadas.

6.1 Gráficos de Dispersão

Para investigar as relações entre as variáveis, foi utilizado o gráfico de dispersão múltipla, gerado pela função sns.pairplot().



Observa-se uma associação positiva entre temperatura e quantidade de aluguéis, enquanto umidade e velocidade do vento apresentam associações negativas com a demanda.

Os gráficos também demonstram dispersão significativa dos registros, indicando que a quantidade de bicicletas alugadas não depende exclusivamente das condições climáticas analisadas.

6.2 Matrizes de Covariância e Correlação de Pearson

Foram calculadas as matrizes de covariância e correlação de Pearson, utilizando as funções cov() e corr() da biblioteca Pandas.

```
========== EXERCÍCIO 05 ==========

========== MATRIZ DE COVARIÂNCIA ==========
                temp         hum  windspeed          cnt
temp        0.033508    0.003310  -0.002241  2.225147e+02
hum         0.003310    0.020286  -0.002743 -2.777323e+01
windspeed  -0.002241   -0.002743   0.006006 -3.521218e+01
cnt       222.514700 -27.773235 -35.212185  3.752788e+06

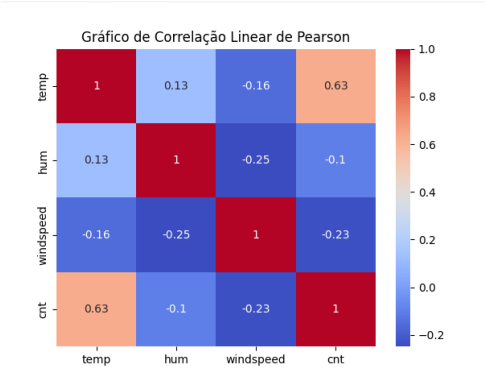
========== MATRIZ DE CORRELAÇÃO ==========
              temp       hum  windspeed       cnt
temp      1.000000  0.126963  -0.157944  0.627494
hum       0.126963  1.000000  -0.248489 -0.100659
windspeed -0.157944 -0.248489   1.000000 -0.234545
cnt       0.627494 -0.100659  -0.234545  1.000000
```

A matriz de covariância indica que temperatura e quantidade de aluguéis tendem a variar no mesmo sentido. Já umidade e velocidade do vento apresentam covariâncias negativas em relação à demanda.

A matriz de correlação demonstra que a temperatura possui a associação linear mais forte com a quantidade de aluguéis (0,6275). A velocidade do vento apresenta correlação negativa de -0,2345, enquanto a umidade possui correlação negativa mais fraca, de -0,1007.

6.3 Gráfico de Correlação Linear De Pearson

Para representar visualmente as correlações, foi construído um mapa de calor utilizando a biblioteca Seaborn.



O gráfico permite identificar a temperatura como a variável climática com maior correlação positiva em relação à demanda. As correlações negativas da umidade e do vento indicam tendências de redução da quantidade de aluguéis quando essas variáveis aumentam, considerando suas associações individuais.

6.4 Regressão Linear Múltipla

Foi construído um modelo de Regressão Linear Múltipla utilizando a biblioteca Statsmodels, considerando as três variáveis climáticas como explicativas.

```
========== REGRESSÃO LINEAR MÚLTIPLA ==========
                            OLS Regression Results
==============================================================================
Dep. Variable:                    cnt   R-squared:                       0.461
Model:                            OLS   Adj. R-squared:                  0.459
Method:                 Least Squares   F-statistic:                     207.2
Date:                Wed, 04 Nov 2026   Prob (F-statistic):          4.26e-97
Time:                        22:06:53   Log-Likelihood:                -6343.9
No. Observations:                 731   AIC:                         1.270e+04
Df Residuals:                     727   BIC:                         1.271e+04
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       4084.3634    337.862     12.089      0.000    3421.061    4747.665
temp        6625.5327    293.085     22.606      0.000    6050.138    7200.927
hum        -3100.1231    383.992     -8.073      0.000   -3853.988   -2346.258
windspeed  -4806.9293    708.904     -6.781      0.000   -6198.673   -3415.186
==============================================================================
Omnibus:                       11.001   Durbin-Watson:                   0.404
Prob(Omnibus):                  0.004   Jarque-Bera (JB):                8.213
Skew:                           0.152   Prob(JB):                       0.0165
Kurtosis:                       2.579   Cond. No.                         18.7
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Equação da Regressão Linear Múltipla:
Y = 4084.3634 + (6625.5327 * X1) + (-3100.1231 * X2) + (-4806.9293 * X3)
```

Onde:

- (Y): quantidade estimada de bicicletas alugadas.
- (X1): temperatura normalizada.
- (X2): umidade normalizada.
- (X3): velocidade do vento normalizada.

O coeficiente positivo da temperatura indica uma associação positiva com a demanda. Os coeficientes negativos da umidade e da velocidade do vento indicam associações negativas, mantendo as demais variáveis constantes.

6.5 Adequação do Modelo - R^2 e Teste F

Para avaliar a adequação estatística da regressão múltipla, foram analisados o coeficiente de determinação (R^2) e o Teste F.

```
========== ADEQUAÇÃO DO MODELO ==========
R²: 0.4608950096446517
Teste F: 207.17712876348483
P-valor do Teste F: 4.2551464401617576e-97
```

O R^2 de 46,09% indica que aproximadamente 46,09% da variabilidade observada na quantidade diária de aluguéis é explicada conjuntamente pelas três variáveis climáticas.

O Teste F apresentou p-valor inferior a 0,05, indicando que o modelo é estatisticamente significativo ao nível de 5%.

Comparado à regressão linear simples, que apresentou R^2 de 39,37%, o modelo múltiplo apresentou maior capacidade explicativa sobre os registros analisados.

6.6 Previsão Utilizando Três Variáveis Explicativas

Foi realizada uma previsão considerando os seguintes valores normalizados:

```
========== PREVISÃO ==========
Temperatura: 0.5
Umidade: 0.6
Velocidade do vento: 0.2
Quantidade prevista: 4576 bicicletas
```

6.7 Interpretação dos Resultados

Os resultados demonstram que a temperatura, a umidade e a velocidade do vento apresentam associações estatísticas com a demanda por bicicletas compartilhadas.

A inclusão das três variáveis explicativas aumentou o R^2 em comparação ao modelo simples, indicando que a análise conjunta das condições climáticas oferece uma representação mais abrangente da variabilidade da demanda.

Entretanto, aproximadamente 53,91% da variação observada permanece sem explicação pelo modelo, sugerindo a influência de outros fatores, como período do ano, feriados e características de utilização do serviço.

Essas informações podem contribuir para o planejamento da disponibilidade de bicicletas, considerando diferentes condições climáticas. As previsões devem ser interpretadas como estimativas baseadas em registros históricos.

7. Regressão Logística Binária

A Regressão Logística Binária foi utilizada para classificar a demanda diária por bicicletas compartilhadas em duas categorias: alta ou baixa. O objetivo foi verificar como as condições climáticas influenciam a probabilidade de ocorrer uma demanda elevada.

Foram utilizados os 731 registros da base de dados e as seguintes variáveis:

- X_1 — temp: temperatura normalizada.
- X_2 — hum: umidade relativa normalizada.
- X_3 — windspeed: velocidade do vento normalizada.
- Y — demanda_alta: classificação binária da demanda.

A variável demanda_alta foi criada a partir da mediana de 4.548 aluguéis diários. Registros com quantidade de aluguéis superior à mediana receberam o valor 1 (demanda alta), enquanto os demais receberam o valor 0 (demanda baixa).

7.1 Equação da Regressão Logística Binária

Para desenvolver o modelo, foi utilizada a função sm.Logit() da biblioteca Statsmodels.

```
========== EXERCÍCIO 06 ==========
Optimization terminated successfully.
         Current function value: 0.497522
         Iterations 6

========== MODELO LOGÍSTICO ==========
                           Logit Regression Results
==============================================================================
Dep. Variable:           demanda_alta   No. Observations:                  731
Model:                          Logit   Df Residuals:                      727
Method:                           MLE   Df Model:                            3
Date:                Wed, 04 Nov 2026   Pseudo R-squ.:                 0.2822
Time:                        22:06:53   Log-Likelihood:                -363.69
converged:                       True   LL-Null:                       -506.69
Covariance Type:           nonrobust   LLR p-value:                 1.064e-61
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const          0.2596      0.579      0.448      0.654      -0.875       1.394
temp           7.9543      0.621     12.812      0.000       6.737       9.171
hum           -4.7329      0.728     -6.503      0.000      -6.159      -3.306
windspeed     -6.3159      1.279     -4.939      0.000      -8.822      -3.810
==============================================================================

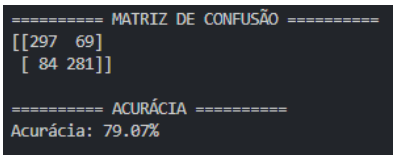
Equação da Regressão Logística Binária:
P(Y=1) = 1 / (1 + e^-(0.2596 + (7.9543 * X1) + (-4.7329 * X2) + (-6.3159 * X3)))
```

O coeficiente positivo da temperatura indica que valores mais elevados dessa variável estão associados ao aumento da probabilidade de demanda alta.

Por outro lado, os coeficientes negativos da umidade e da velocidade do vento indicam associações com a redução dessa probabilidade, mantendo as demais variáveis constantes.

7.2 Matriz de Confusão e Acurácia

Para avaliar as classificações realizadas pelo modelo, foram utilizadas a matriz de confusão e a acurácia.



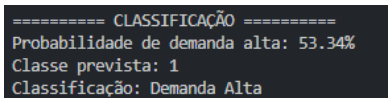
A matriz apresenta 297 verdadeiros negativos, 281 verdadeiros positivos, 69 falsos positivos e 84 falsos negativos.

O resultado indica que o modelo classificou corretamente aproximadamente 79,07% dos registros avaliados.

Entretanto, a avaliação foi realizada utilizando os mesmos dados empregados no treinamento. Portanto, a acurácia apresentada representa o desempenho do modelo sobre os registros utilizados no ajuste, não sendo uma medida independente de sua capacidade de prever novos dados.

7.3 Classificação de uma Nova Observação

Foi realizada uma classificação utilizando três variáveis explicativas com os seguintes valores normalizados:



Aplicando esses valores ao modelo logístico, foi obtida uma probabilidade de 53,34% de ocorrer demanda alta.

Como essa probabilidade é superior ao limite de classificação de 50%, o registro foi classificado como:

Classe prevista: 1 — Demanda Alta.

Esse resultado demonstra a aplicação do modelo na classificação da demanda a partir das condições climáticas informadas.

7.4 Interpretação dos Resultados

Os resultados demonstram que a Regressão Logística Binária permite utilizar variáveis climáticas para estimar a probabilidade de ocorrer uma demanda elevada por bicicletas compartilhadas.

A temperatura apresentou associação positiva com a classificação de demanda alta, enquanto umidade e velocidade do vento apresentaram associações negativas.

A acurácia de 79,07% demonstra que o modelo conseguiu classificar corretamente a maior parte dos registros históricos utilizados no treinamento, embora seja necessária uma avaliação com dados não utilizados no ajuste para verificar sua capacidade de generalização.

Dessa forma, a Regressão Logística Binária representa uma ferramenta estatística útil para apoiar a identificação de períodos com maior ou menor demanda por bicicletas compartilhadas.

8. Resultados, Insights e Recomendações

As análises estatísticas realizadas no projeto CitizenBike permitiram identificar padrões relacionados à demanda por bicicletas compartilhadas e investigar a associação entre as condições climáticas e a quantidade diária de aluguéis.

Os resultados foram obtidos a partir de 731 registros reais, utilizando técnicas de probabilidade, testes de hipótese, análise bivariada, regressão linear simples, regressão linear múltipla e regressão logística binária.

8.1 Resumo dos Resultados

A tabela apresenta os principais resultados obtidos durante o desenvolvimento do projeto.

Análise	Principal resultado
Probabilidade	50,00% abaixo da média e 49,10% acima da mediana, sob a hipótese de normalidade
Testes de hipótese	Não rejeição de H_0 nos dois testes
Correlação de Pearson	0,6275 entre temperatura e aluguéis
Regressão Linear Simples	R^2 de 39,37%
Regressão Linear Múltipla	R^2 de 46,09%
Regressão Logística Binária	Acurácia de 79,07% nos dados de treinamento

Os resultados indicam que as condições climáticas apresentam associações relevantes com a quantidade de bicicletas alugadas, especialmente a temperatura.

8.2 Principais Insights

Influência da temperatura

A temperatura apresentou correlação positiva de 0,6275 com a quantidade diária de aluguéis, representando a associação linear mais forte entre as variáveis climáticas analisadas.

Esse resultado indica que dias com temperaturas mais elevadas tendem a apresentar maior utilização do serviço de bicicletas compartilhadas.

Influência da umidade e do vento

A umidade e a velocidade do vento apresentaram correlações negativas com a quantidade de bicicletas alugadas, respectivamente -0,1007 e -0,2345.

Esses resultados sugerem que condições de maior umidade e vento estão associadas a uma menor demanda pelo serviço nos registros analisados.

Comparação dos modelos de regressão

A Regressão Linear Simples apresentou R^2 de 39,37%, enquanto a Regressão Linear Múltipla alcançou 46,09%.

A inclusão das variáveis umidade e velocidade do vento aumentou a capacidade explicativa do modelo em aproximadamente 6,72 pontos percentuais, demonstrando a importância de considerar diferentes condições climáticas simultaneamente.

Classificação da demanda

A Regressão Logística Binária apresentou acurácia de 79,07% nos registros utilizados para o treinamento.

Esse resultado demonstra que o modelo conseguiu identificar corretamente a maior parte das classificações históricas de demanda alta e baixa, embora seja necessária uma avaliação independente para determinar seu desempenho em novos registros.

8.3 Recomendações

Com base nos resultados estatísticos, podem ser apresentadas as seguintes recomendações para sistemas de bicicletas compartilhadas:

1. **Planejamento da disponibilidade:** considerar previsões de temperatura para auxiliar na distribuição de bicicletas em períodos de maior demanda esperada.
2. **Análise das condições climáticas:** utilizar temperatura, umidade e velocidade do vento conjuntamente para produzir estimativas mais abrangentes da demanda.
3. **Monitoramento da utilização:** acompanhar os registros de aluguéis para identificar padrões de utilização e possíveis variações na procura pelo serviço.
4. **Aprimoramento dos modelos:** incluir outras variáveis, como feriados, dias da semana e estações do ano, para investigar possíveis melhorias na capacidade preditiva.
5. **Validação futura:** avaliar os modelos com dados não utilizados no treinamento antes de aplicá-los em decisões operacionais.

8.4 Limitações da Análise

Apesar dos resultados obtidos, o estudo apresenta limitações importantes.

A base de dados contempla registros históricos de 2011 e 2012, não representando necessariamente as condições atuais de utilização de bicicletas compartilhadas.

Além disso, os modelos foram desenvolvidos considerando um conjunto limitado de variáveis climáticas. Outros fatores, como infraestrutura, disponibilidade de bicicletas, localização e características dos usuários, também podem influenciar a demanda.

Os modelos lineares explicaram apenas parte da variabilidade observada. A avaliação da regressão logística também foi realizada sobre os próprios dados de treinamento, o que limita conclusões sobre sua capacidade de generalização.

Por fim, as associações estatísticas identificadas não demonstram, isoladamente, relações de causa e efeito.

Dessa forma, os resultados devem ser interpretados como informações exploratórias e preditivas baseadas nos dados históricos analisados, podendo servir de apoio para estudos e decisões futuras relacionados à mobilidade urbana.

9. Conclusão

O desenvolvimento do projeto CitizenBike permitiu aplicar técnicas estatísticas e modelos de regressão para analisar a demanda por bicicletas compartilhadas, utilizando dados reais e a linguagem de programação Python.

Por meio das análises de probabilidade e dos testes de hipótese, foi possível investigar características da distribuição da quantidade diária de aluguéis e realizar comparações entre médias amostrais e a média populacional de referência.

A análise bivariada identificou uma correlação positiva de 0,6275 entre temperatura e quantidade de bicicletas alugadas. A Regressão Linear Simples apresentou R^2 de 39,37%, enquanto a Regressão Linear Múltipla alcançou 46,09%, demonstrando maior capacidade explicativa ao considerar temperatura, umidade e velocidade do vento conjuntamente.

A Regressão Logística Binária apresentou acurácia de 79,07% nos registros utilizados no treinamento, demonstrando sua aplicação na classificação da demanda em alta ou baixa.

Os resultados indicam que as condições climáticas possuem associações relevantes com a utilização de bicicletas compartilhadas, podendo contribuir para estudos relacionados ao planejamento da mobilidade urbana.

Entretanto, as análises apresentam limitações relacionadas ao período histórico dos dados, às variáveis selecionadas e à necessidade de validar os modelos com novos registros.

Conclui-se que o projeto atingiu seus objetivos de análise estatística, identificação de padrões e desenvolvimento de modelos preditivos, demonstrando como a utilização de dados reais pode apoiar a compreensão de problemas relacionados à mobilidade urbana e contribuir para o desenvolvimento de soluções tecnológicas alinhadas ao desafio CitizenTech.